

Propuesta de Trabajo

Análisis, Monitorización y Diagnóstico de Procesos Multivariantes · UPV

Alumno: José Ramón Mena Pérez

0. Título

Comparación de métodos multivariantes para la predicción de indicadores de calidad del suelo en África a partir de espectros de infrarrojo medio (MIR) y variables edáficas, topográficas, climáticas y de teledetección.

1. Descripción de la base de datos

Dataset: Africa Soil Property Prediction Challenge (Kaggle, 2014), disponible en <https://www.kaggle.com/competitions/afsis-soil-properties>. Se trata de un challenge internacional ya finalizado cuyo objetivo era predecir cinco variables de calidad del suelo a partir de espectros de infrarrojo medio y variables edáficas, topográficas, climáticas y de teledetección, como alternativa rápida y accesible al análisis químico convencional de laboratorio, que resulta bastante más lento y costoso, en zonas rurales de África subsahariana. Esto hace que el objetivo del trabajo sea especialmente interesante desde el punto de vista aplicado.

Observaciones: 1 157 muestras de suelo en entrenamiento. El conjunto de test oficial contiene 728 observaciones sin variables respuesta, de manera que nuestros splits se basarán únicamente en las muestras de entrenamiento.

Variables predictoras X (3 593, todas cuantitativas continuas):

- 3 578 variables espectrales MIR: absorbancia en $599\text{--}7\,498\text{ cm}^{-1}$, con una lectura cada 1.93 cm^{-1} aproximadamente.
- 15 variables edáficas, topográficas, climáticas y de teledetección: índice de vegetación (EVI), temperatura superficial diurna y nocturna (LSTD, LSTN), elevación (ELEV), reflectancias espectrales (REF1–REF7), precipitación media anual (TMAP), índice de humedad topográfica (CTI) e índices BIOS (BSAN, BSAS, BSAV), entre otras.

Variable categórica: Depth, con dos niveles, Topsoil y Subsoil. Se excluye del modelo predictivo, pero se utiliza en el análisis exploratorio.

Variables respuesta Y:

Variable	Descripción	Unidades
Ca	Calcio intercambiable	cmol/kg
P	Fósforo disponible	ppm
pH	Acidez del suelo	—
SOC	Carbono orgánico del suelo	%
Sand	Contenido de arena	%

El dataset no presenta datos faltantes y combina **colinealidad extrema** y situación $K(\text{variables}) \gg N(\text{observaciones})$. Los métodos PCA, PCR y PLS están diseñados para afrontar las dos situaciones simultáneamente y esa es una de las principales motivaciones por las cuales creemos que este dataset tiene potencial para aplicar las técnicas aprendidas en la asignatura y obtener resultados interesantes.

2. Preguntas y métodos

La propuesta plantea una comparación sistemática entre métodos de variables latentes y modelos de referencia bajo un mismo esquema de validación.

- P1.** ¿Existe estructura latente en los espectros MIR y en las variables auxiliares? ¿Cuántas componentes resumen X? ¿Hay outliers?
PCA sobre X (MIR + variables auxiliares), con Scree Plot, Score Plot, Loadings y diagnóstico de outliers mediante T^2 y SCR/DModX.
- P2.** ¿La información conjunta de espectros MIR y variables auxiliares distingue muestras de Topsoil y Subsoil?
Proyección de Depth sobre el espacio PCA para comprobar separación entre horizontes.
- P3.** ¿Cuántas variables latentes permiten predecir con máxima precisión las cinco variables respuesta y qué regiones espectrales o variables auxiliares son más relevantes?
PLS2 como modelo principal, **PCR** como comparación y **VIP Scores** para interpretar longitudes de onda y variables auxiliares relevantes.
- P4.** ¿Superan los métodos de variables latentes a los modelos de referencia y cuál es el compromiso entre capacidad predictiva y coste computacional?
Ridge, **Random Forest** y **perceptrón multicapa** como referencias. Comparación mediante Q^2 , R^2_{test} y coste computacional.