

PLS

(Proyección a estructuras latentes por medio de Mínimos Cuadrados Parciales)

Herman Wold (Años 70)

Svante Wold y Harald Martens (años 80)

Alberto J. Ferrer Riquelme

Dpto. Estadística e I.O. Aplicadas y Calidad - Universidad Politécnica de Valencia (España)



UNIVERSITAT
POLITÈCNICA
DE VALÈNCIA



PLS: Mínimos Cuadrados Parciales; Proyección a Estructuras Latentes

- Introducción / motivación
- Interpretación geométrica
- Solución algebraica
- Algoritmo
- Gráficos PLS
- Ejemplo: optimización de un polímero
- Validación del modelo:
 - Diagnóstico de observaciones
 - Diagnóstico de variables
- Explotación del modelo: predicciones
- Datos faltantes
- Ejemplos
- PLS: cuestiones adicionales




UNIVERSITAT
POLITÈCNICA
DE VALÈNCIA



42

Regresión lineal múltiple (MLR)

$$\mathbf{y} = \mathbf{X}\mathbf{b} + \mathbf{e}$$
$$\mathbf{b} = (\mathbf{X}^T\mathbf{X})^{-1}\mathbf{X}^T\mathbf{y}$$
$$\mathbf{y}^* = \mathbf{X}\mathbf{b}$$



Regresión lineal múltiple (MLR)

- Los valores en $\mathbf{X}$ se asumen **exactos** (sin ruido) y **completos** (sin datos faltantes)
- **No modela el espacio $\mathbf{X}$** , solo su relación con $\mathbf{y}$
- Si las variables $\mathbf{X}$ están relacionadas, los estimadores $\mathbf{b}$ son **inestables** (gran variabilidad). La correlación en $\mathbf{X}$ es un "problema"
- Requiere más individuos que variables $\mathbf{X}$ ($N > K$)
- Si hay varias respuestas, ajusta **un modelo para cada $\mathbf{y}$** (no aprovecha la posible relación entre las respuestas)

Regresión lineal múltiple (MLR) con X correlacionados

Set A		Set B		
x_1	x_2	x_1	x_2	y
-1.01	-0.99	-1.01	-0.99	-0.89
3.23	3.25	3.23	3.25	10.33
5.49	5.55	5.49	5.55	16.29
0.23	0.21	0.23	0.23	-1.91
-2.87	-2.91	-2.87	-2.91	-8.59
3.67	3.76	3.67	3.76	10.79
2.48	2.53	2.48	2.53	7.04
-0.73	-0.68	-0.73	-0.68	-3.19
1.68	1.67	1.68	1.67	4.82
4.34	4.28	4.34	4.28	12.90
-1.82	-1.88	-1.82	-1.88	-5.18

$$y^* = \beta_1^* x_1 + \beta_2^* x_2$$


MLR	β_1^*	β_2^*	β_1^*	β_2^*
	-1.55	4.59	1.00	2.07

$$R_A^2 = 0.96$$

$$R_B^2 = 0.96$$


Regresión lineal múltiple (MLR) con X correlacionados

$$y^* = \beta_1^* x_1 + \beta_2^* x_2$$



Regresión lineal múltiple (MLR) con X correlacionados


$$y^* = \beta_1^* x_1 + \beta_2^* x_2$$



Diferentes modelos con predicciones similares

¡Ojo con la interpretación de coeficientes beta*!

MLR: Correlation does not necessarily mean causation!!



While we may predict the **weight** of a person from their **height**...

... we shouldn't try to optimize our **weight**, by decreasing our **height**! (i.e. cut our legs)

**With models built on measured variables (MLR, SVM, NN, RF,...),
happenseance data (not from DOE) cannot be used to infer causality!!!**

DON'T!



Regresión lineal múltiple (MLR)

In this context, classical predictive models (such as linear regression and machine learning models), proven to be very powerful in passive applications, cannot be used for process optimization (active use). They cannot be used for extracting interpretable or causal models from historical data for active use. With historical data, there are an infinite number of models that can arise from any of these linear regression or machine learning methods, all of which might provide good predictions of the outputs, but none of which is unique or causal. Because the process variables are all highly correlated and the number of independent variations in the process is much smaller than the number of measured variables, one can get many of those models all using different variables and having different weights or coefficients on the variables that give nearly identical predictions. This does not allow for meaningful interpretations, even more so if the results come from averaging or voting on many models, such as in random forest (MacGregor 2018). This is the essence of the Box et al (2005)'s warning: predictive models based on correlated inputs must not be used for process optimization if they are built from observational data (i.e. data not coming from a DOE). Note that this is a mistake that is beginning to occur in industry 4.0 with the indiscriminate use of machine learning tools.

Regresión en componentes principales (PCR): 1 resp.

Paso 1. PCA sobre $\mathbf{X}$:


$$\mathbf{T} = \mathbf{X}\mathbf{P}$$

Paso 2. MLR de scores $\mathbf{T}$ sobre $\mathbf{y}$:

$$\mathbf{y} = \mathbf{T}\mathbf{b} + \mathbf{e}; \quad \mathbf{b} = (\mathbf{T}^T\mathbf{T})^{-1}\mathbf{T}^T\mathbf{y}$$

$$\mathbf{y}^* = \mathbf{X}\mathbf{P}\mathbf{b} = \mathbf{X}(\mathbf{P}\mathbf{b}) = \mathbf{X}\mathbf{b}_{\text{PCR}}$$

Donde $\mathbf{b}_{\text{PCR}}$ vector de coeficientes que expresan la relación de las $\mathbf{X}$ sobre la $\mathbf{y}$




Regresión en componentes principales (PCR): >1 resp.

Paso 1. PCA sobre $\mathbf{X}$ y PCA sobre $\mathbf{Y}$: $\mathbf{T} = \mathbf{XP}$; $\mathbf{U} = \mathbf{YC}$

Paso 2. MLR de scores $\mathbf{T}$ sobre cada $\mathbf{u}$: $\mathbf{U} = \mathbf{TB} + \mathbf{F}$; $\mathbf{B} = (\mathbf{T}^T \mathbf{T})^{-1} \mathbf{T}^T \mathbf{U}$

$$\mathbf{Y}^* = \mathbf{XPBC}^{-1} = \mathbf{X}(\mathbf{PBC}^{-1}) = \mathbf{XB}_{\text{PCR}}$$

Donde $\mathbf{B}_{\text{PCR}}$ matriz de coeficientes que expresan la relación de las $\mathbf{X}$ sobre las $\mathbf{Y}$




Regresión en componentes principales (PCR)


- Puede manejar valores $\mathbf{X}$ con ruido y faltantes
- Sí modela el espacio $\mathbf{X}$: detección de anomalías mediante SCR
- Los scores $\mathbf{T}$ son ortogonales: estimadores MLR estables
- No requiere más individuos que variables $\mathbf{X}$ ($N < K$)
- Aprovecha la posible relación entre variables respuesta
- Los scores $\mathbf{T}$ explican fuentes de variabilidad en $\mathbf{X}$ que no tiene por qué estar relacionadas con las $\mathbf{y}$'s. Puede ser que scores que explican poco $\mathbf{X}$ estén muy relacionados con las $\mathbf{y}$'s. Aconsejable extraer muchas componentes principales.

PLS: Proyección a Estructuras Latentes

Dos espacios de datos



Datos del Proceso



Datos de Calidad
y Productividad

- **PLS** - Explica la **variación** en **X** e **Y** y la **relación** entre **X** e **Y**
 - Maximiza la **Covarianza** $(X, Y) = \sigma_X \sigma_Y \text{Corr}(X, Y)$
- Las variables latentes explican variabilidad en **X** relacionada con la **Y**
- Reduce el proceso en 2 pasos del PCR a un solo paso

PLS: Modelización Cuantitativa


- Encontrar las relaciones entre conjuntos de datos multivariantes **X** e **Y**
- Predecir un conjunto a partir del otro para nuevas observaciones $x_i \Rightarrow y_i$

Aplicaciones:

- Modelización de procesos y optimización
- Medidas físicas de la composición química $\Leftrightarrow$
 - Calidad
 - Actividad Biológica
- Estructura química $\Leftrightarrow$
 - Reactividad
 - Actividad Biológica
- Espectros $\Leftrightarrow$
 - Concentraciones
 - Otras Propiedades
 - * contenido de energía
 - * edad
 - * sabor...


PLS

- Observaciones:
 - Muestras analíticas
 - Compuestos químicos
 - Instantes de tiempo en un proceso continuo
 - Lotes de un proceso por lotes
 - Individuos biológicos
 - Pruebas de un diseño de experimentos
- Factores:
 - De origen espectroscópico o cromatográfico
 - Lecturas de sensores y dispositivos en un proceso
- Respuestas:
 - Cantidades de producto
 - Cantidades de impurezas
 - Calidad del Producto





PLS: Interpretación geométrica

Ejemplo con $K=3$, $M=3$





- Para cada matriz X e Y se construye un espacio de K y M dimensiones, respectivamente.
- La longitud de cada eje coordenado (variable) se reescala generalmente a varianza unitaria.

PLS: Interpretación geométrica




- Cada observación se representa con un punto en el espacio X y con un punto en el espacio Y .
- Las matrices de datos X y Y , por tanto, representan dos nubes de puntos conectadas entre estos dos espacios.

PLS: Interpretación geométrica




- Se calcula la media de cada variable. Los vectores de medias de las variables son puntos en los espacios X e Y .
- Estas medias se restan de la matriz de datos. Esto es equivalente a mover el origen del sistema de coordenadas al centro de la nube de datos.

PLS: Interpretación geométrica




- El procedimiento del centrado supone que el origen de cada uno de los dos sistemas de coordenadas pasa por el punto medio (punto negro) en cada nube de puntos.
- Cada observación sigue estando representada por un punto en el espacio X y por otro punto en el espacio Y.

PLS: Interpretación geométrica



- La primera componente PLS es una recta en el espacio X y una recta en el espacio Y tal que:
 - las rectas **aproximen** bien los datos ($\min SCR_X$ y SCR_Y)
 - las proyecciones (scores t_1 y u_1) estén bien **correlacionadas**
- Las rectas pasan por los puntos medios de las nubes.

PLS: Interpretación geométrica



- **Relación lineal**

Las coordenadas de las proyecciones de los individuos en los dos subespacios (t_1 en X y u_1 en Y) están relacionadas a través de la relación interna:

$$u_{1i} = b_1 t_{1i} + h_i \quad (h_i \text{ es el residuo})$$

$$b_1 = 1 \text{ si } \|c_1\| \neq 1$$

- **Relación no lineal** entre los factores predictores y las respuestas:

1. Transformaciones

2. PLS no lineal:

- Expandir la matriz X con términos de 2º orden (centrado y escalado previos):


$$X_k * X_k, X_k^2$$

- Usar relaciones externas ($X \Rightarrow Y$) lineales y relaciones internas ($t \Rightarrow u$) no lineales:

$$\hat{U}_a = f(t_a)$$


f: polinomial, spline, exponencial, modelo de red neuronal sigmoidal....

PLS: Interpretación geométrica



- La segunda componente PLS se representa por dos rectas, una en cada espacio de variables, que pasan por la media de la nube de puntos.
- En el espacio X, esta segunda componente es ortogonal a la primera, sin embargo en el espacio Y esto no se debe cumplir necesariamente. Las dos componentes mejoran la aproximación y la correlación entre X e Y lo máximo posible.
- Las componentes PLS juntas forman planos (hiperplanos) en el espacio X e Y. Al proyectar las observaciones sobre estos planos se obtienen los vectores de "scores" para la 1ª componente (t_1, u_1) y 2ª componente (t_2, u_2), así como los vectores de residuos.

PLS: Interpretación geométrica



- El segundo par de vectores "score", t_2 y u_2 , también están correlacionados linealmente, aunque, generalmente, su grado de relación lineal es inferior al de la primera pareja t_1 y u_1 , ya que esta última captura la mayor fuente de variación y correlación entre X e Y .

Algoritmo del PLS 2

1. Iniciar con u (la columna con más varianza de Y)

2. $w' = u'X / u'u \rightarrow ||w|| = 1$

3. $t = Xw$

4. $c' = t'Y / t't$


5. $u = Yc / c'c$

6. En la convergencia: $p' = t'X / t't$


7. Residuos: $E = X - tp'$ $F = Y - tc'$

$$b = t'u / t't = t'Yc / c'c \quad t't = c'c / c'c = 1$$

- Una dimensión cada vez
- Si se quieren más componentes PLS, reemplazar X e Y por E y F , respectivamente, y volver al paso 1
- Número de componentes mediante validación cruzada



PLS: Modelo expresado en función de las variables latentes



$$t_1 = Xw_1; t_2 = (X - t_1 p_1^T)w_2; \dots$$

$$X = 1 \bar{x}^T + TP^T + E$$

$$Y = 1 \bar{y}^T + UC^T + G = 1 \bar{y}^T + TC^T + F$$

$$U = T + H \quad (\text{relación interna})$$

PLS

proyección de **X** *aproxima* bien **X** e **Y**
y *maximiza* la **correlación** con **Y**

Diferencias

PCA

proyección de **X** es una *aproximación*
óptima de **X** (mínimos cuadrados)


PLS: Notación e interpretación

- t** "scores" en el espacio **X** (coordenadas en el (hiper)-plano definido en R^K)
- u** "scores" en el espacio **Y** (coordenadas en el (hiper)-plano definido en R^M)
- w** correlaciones entre **X** y **u**(**Y**) $\Rightarrow$ **t** (CL de **X**'s con pesos **w**)
- c** correlaciones entre **Y** y **t**(**X**) $\Rightarrow$ **u** (CL de **Y**'s con pesos **c**)
- p** dirección de la componente en el espacio **X** (cargas)

Relaciones ortogonales:

$$t_a \text{ y } t_b \quad \text{si } a \neq b$$


$$w_a \text{ y } w_b \quad \text{si } a \neq b$$



Modelo PLS


$$X = TP^T + E$$

$$\text{Maximizar } \text{cov}(t_a, u_a) = r(t_a, u_a) \sigma(t_a) \sigma(u_a)$$



Diferencias entre w y p

- w**: coeficientes de correlación entre las x 's y u . Las variables X que tengan mayor correlación con las variables Y tendrán mayores pesos w
- t**: combinación lineal de las variables X con pesos w (pesos de las variables originales X en la nueva variable latente)
- t**: resumen de las variables X que están correlacionadas con Y



3. En la convergencia:

- p** se calcula de forma que tp^T sea la "mejor aproximación" de X . Se intenta reconstruir (predecir) X a partir de t , siendo p el vector de coeficientes de regresión.
- tp^T se resta de X para obtener la matriz residual de la que se obtendrá la nueva componente

Gráficos PLS: Interpretación del modelo

- Espacio X : scores t/t
pesos w/w
pesos w^*/w^*
- Espacio Y : scores u/u
pesos c/c
- Espacio X+Y : scores t/u
pesos wc/wc ($w/w + c/c$)
pesos w^*c/w^*c ($w^*/w^* + c/c$)
- Gráficos de los scores (t, u) / observaciones
- Gráficos de los pesos (w, w^*) / variable X
- Gráficos de los pesos c / variable Y


PLS: características

- Puede manejar valores X con ruido y faltantes
- Modela el espacio **X** (detección de anomalías mediante SCR), el espacio **Y** y la relación entre **X** e **Y**
- Los scores **T** son ortogonales
- No requiere más individuos que variables X ($N < K$)
- Aprovecha la posible relación entre variables respuesta
- Los scores **T** explican fuentes de variabilidad en **X** relacionadas con la fuentes de variabilidad en **Y**
- Herramientas gráficas para explorar, diagnosticar y comprender

Causality in Latent Variable models

- In **passive** application of LV models **no causality** is required
 - Model use only requires that future data follow the same structure
 - No causality is implied or needed among the variables for use of the model
 - Calibration; soft sensors; process monitoring
- For **active** use such as in optimization and control one **needs causal models**
 - For empirical models to be causal in certain x-variables – we need to have data with independent variation (DOE's) in those x's.
 - But most process modeling uses “happenstance data” that arise in the natural operation of the process
 - They don't give causal models for the effect of individual x's on the y's
 - But LV models do provide causal models in the low dimensional LV space
 - If we move in LV space ($t_1, t_2, \dots$) we can predict the causal effects of these moves on X and Y thru the X and Y space models
 - This fact together with the model of the X-space allow us to perform optimization in the LV spaces

Optimization by PLS model inversion



Causality in Latent Variable models



- Pulling the cord makes all limbs move
 All limbs are related
- Moving a limb doesn't affect any other
 No causal relationship among limbs
- A causal relationship exists between the cord (latent variable) and the movement of all limbs (4 'x' variables)
- Causal relationships among the latent variables can be inferred



ALREADY AVAILABLE DATA CAN BE EXPLOITED TO IMPROVE/OPTIMIZE OUR PROCESSES

Comparación: MLR, PCR y PLS

Set A		Set B		
x ₁	x ₂	x ₁	x ₂	y
-1.01	-0.99	-1.01	-0.99	-0.89
3.23	3.25	3.23	3.25	10.33
5.49	5.55	5.49	5.55	16.29
0.23	0.21	0.23	0.23	-1.91
-2.87	-2.91	-2.87	-2.91	-8.59
3.67	3.76	3.67	3.76	10.79
2.48	2.53	2.48	2.53	7.04
-0.73	-0.68	-0.73	-0.68	-3.19
1.68	1.67	1.68	1.67	4.82
4.34	4.28	4.34	4.28	12.90
-1.82	-1.88	-1.82	-1.88	-5.18

$$y = \beta_1 x_1 + \beta_2 x_2$$

	β_1	β_2	β_1	β_2
MLR	-1.55	4.59	1.00	2.07
PCR	1.54	1.53	1.54	1.53
PLS	1.65	1.64	1.65	1.64

$$R^2_A = 0.96$$

$$R^2_B = 0.96$$

Ejemplo: Optimización de un polímero


OBJETIVO: conseguir un polímero que se deforme poco y tenga gran resistencia.

- 4 factores (variables **X**): GLASS, CRTP, MICA, AMTP
- 14 respuestas (variable **Y**): def1 – def8, res1 – res6
- 17 formulaciones (observaciones) según un diseño de mezclas (“mixture design”)




Gráficos de los scores t_1 / t_2 (Espacio X)

- Son como “ventanas” en el espacio original R^k de las variables **X** que muestran las **observaciones** (individuos) tal y como quedan **proyectadas** en el plano (o hiperplano) definido por las nuevas componentes.
- Las **coordenadas de los individuos** en cada una de las componentes (variables latentes) que definen el **nuevo subespacio** vienen recogidas en el vector de scores de cada nueva componente t_a .
- Pueden representarse regiones de confianza elípticas (normalmente al 95 ó 99 %) basadas en la T^2 de Hotelling.
- Son útiles para comprender la **relación entre las observaciones** (parecidos, diferencias, agrupamientos, tendencias, etc.)




Gráficos de los scores u / u (Espacio Y)




- Análogamente pueden representarse gráficos de los scores u/u que son “ventanas” en el espacio original R^M de las variables y que muestran las **observaciones proyectadas** en el plano (o hiperplano) definido por las nuevas componentes.

Gráficos de los scores u / t (Espacio X + Y)




- Permiten estudiar la relación entre los scores $t(X)$ y los scores $u(Y)$ (**relación interna**) para cada una de las nuevas componentes (variables latentes).
- Indican el grado de **correlación** de las variables Y con las variables X

Gráficos de los pesos w / w (Espacio X)



- Expresan la **correlación** entre las variables X (en la 1ª dimensión), o los residuos de las variables X (en las siguientes dimensiones), y los scores de Y (en la 1ª dimensión) o de los residuos de Y (en las siguientes dimensiones), $U(Y)$.
- Variables X con grandes valores w (en valor absoluto) estarán altamente correlacionadas con $U(Y)$.

Gráficos de los pesos w^* / w^* (Espacio X)




- Los pesos w^* son diferentes a los w . Expresan la **correlación** entre las variables X, en todas las dimensiones, y las variables respuesta Y.
- En la 1ª dimensión $w_1^* = w_1$ y $t_1 = Xw_1 = Xw_1^*$
- En las siguientes dimensiones, los w^* son los pesos que combinarán las variables originales X (no sus residuos, como con w) para formar los scores t . V.g. y $t_2 = (X - t_1 p_1)w_2 = Xw_2^*$

$$W^* = W (P^T W)^{-1}$$

- w^* están directamente relacionados con los coeficientes de regresión del modelo PLS.


$$Y = X B_{PLS}$$

Gráficos de los pesos c / c (Espacio Y)



- Expresan la **correlación** entre las variables Y y los scores T(X).
- Dan los pesos que combinan las variables Y para formar los scores u de forma que se maximice la correlación con las variables X.
- Variables Y con altos valores c (en valor absoluto) estarán altamente correlacionadas con T(X)

Gráficos de los pesos w^*c / w^*c (Espacio X + Y)



- Superposición de los gráficos w^*/w^* y c/c (**relaciones** entre los **factores** y las **respuestas** al mismo tiempo). W^* y C comparten un vínculo común, $T = XW^*$ y $T = YC - H$
- Muestran la estructura de **correlación entre X e Y**. Dan información sobre cómo las variables se combinan para formar la relación cuantitativa entre X e Y.
- Los pesos son esenciales para comprender:
 - qué variables X son importantes en la relación (altos $|w^*|$),
 - qué variables X proporcionan la misma información (valores parecidos de los w^* en las diferentes componentes),
 - la interpretación de los scores, t .

Coeficientes de regresión PLS

- El modelo PLS expresado en función de las variables latentes:

$$\mathbf{Y} = \mathbf{T}\mathbf{C}^T + \mathbf{F} = \mathbf{X}\mathbf{W}^*\mathbf{C}^T + \mathbf{F} = \mathbf{X}\mathbf{W}(\mathbf{P}^T\mathbf{W})^{-1}\mathbf{C}^T + \mathbf{F}$$

puede representarse como un modelo de regresión clásico:

$$\mathbf{Y} = \mathbf{1}\bar{\mathbf{y}}^T + \mathbf{X}\hat{\mathbf{B}}_{PLS} + \mathbf{F}$$

$\hat{\mathbf{B}}_{PLS}$: matriz de K filas (nº términos X), M columnas (nº variables Y)

- La relación entre los coeficientes de regresión PLS y los pesos PLS viene dado por:

$$\hat{\mathbf{B}}_{PLS} = \mathbf{W}(\mathbf{P}^T\mathbf{W})^{-1}\mathbf{C}^T = \mathbf{W}_{(K,A)}^* \mathbf{C}_{(A,M)}^T$$

(coeficientes escalados y centrados)

Coeficientes de regresión PLS


- Ventajas:

- Facilitan la **interpretación** del modelo cuando el número de variables latentes es grande (>4)
- Se obtiene un vector con información precisa por cada variable y_m (no varios vectores de pesos)

$$\text{➤ } y_m = b_{1m}x_1 + b_{2m}x_2 + \dots + b_{Km}x_K + f_m$$

- La **magnitud** y el **signo** de los coeficientes de regresión b_{km} (escalados y centrados) indican la influencia de cada término x_k del modelo sobre la variable y_m . Pueden obtenerse I de C (95%) mediante remuestreo.
- Facilitan la explicación de los resultados a personas no expertas
- Desventaja:** se pierde la información relativa a la estructura de correlación entre las respuestas


Coeficientes de regresión PLS (2 componentes)



VIP: Influencia de la variable x_k en la proyección

VIP (Variance Influence on Projection parameter)

- **VIP_k**: Mide la **importancia relativa** de la variable x_k en la definición del espacio de proyección en conjunto. Es otra forma de mostrar la importancia de los términos del modelo para:
 - explicar Y
 - explicar la proyección en X
- **VIP_k**: Es una medida acumulada de la influencia de cada variable x_k sobre todas las variables y_m



VIP: Influencia de la variable x_k en la proyección

VIP (Variance Influence on Projection parameter)

$$(VIP_k)^2 = n \left(\sum_a w_{ak}^2 \text{SCEY}(a) \right) / \text{SCEY}(\text{total})$$

- **SCEY(a)** = Suma de cuadrados total de las variables y_m explicada por la componente PLS a-ésima.
- **SCEY(total)** = Suma de cuadrados total de las variables y_m explicada por el modelo con A componentes
- **n**: nº de términos del modelo (= K si no se añaden nuevos términos)

Ventaja: en cada modelo PLS, por complejo que sea, sólo hay un vector VIP resumiendo todas las componentes y variables Y

- **Interpretación:** $\begin{cases} VIP_k > 1 & \text{término } x_k \text{ muy relevante para la proyección} \\ VIP_k < 0.8 & \text{término } x_k \text{ poco relevante} \end{cases}$


- **Recomendación:** seleccionar variables X con $VIP > 1$

– Nota: Usar también información de los coeficientes b_{PLS} estadísticamente significativos.



Validación del modelo: Diagnóstico de observaciones

¿"Outliers" severos (observaciones **EXTREMAS**)?


¿Relaciones no lineales $X \rightarrow Y$?



Algunas observaciones pueden ser "outliers" en ambos espacios X e Y




Los "outliers" constituyen un serio problema pero son fáciles de detectar



Validación del modelo: Diagnóstico de observaciones

Una observación pueden ser anómala ("outlier") en:

- Espacio X (variación en las condiciones operativas de las variables del proceso)
- Espacio Y (fluctuaciones de calidad)
- Espacio X e Y
- Espacio t/u (Espacio X+Y) (en la relación entre x e y)



- Gráficos de Scores PLS detectan los "outliers"

t_1 vs t_2 (T^2 - Hotelling)

u_1 vs u_2

t_1 vs u_1 (relaciones no lineales), ...

T^2 - Hotelling

- T^2 es un resumen de los "scores" t en todas las A dimensiones.
- T^2 es una medida de la **distancia** desde la **proyección** de una observación al **centro** del modelo (plano o hiperplano de las nuevas componentes).
- El valor T^2_i para la observación i (A componentes):

$$T^2_i = \sum_{a=1}^A t_{ia}^2 / s_{ta}^2 = t_i' \text{diag}(1/s_{ta}^2) t_i = t_i' (T'T/N-1)^{-1} t_i$$

s_{ta}^2 = varianza de t_a (variable latente a en X)

$$T^2_i N(N-A) / A(N^2-1) \sim F_{A, N-A}$$

N = número de observaciones en el "training set"


A = número de componentes en el modelo

T² - Hotelling

- La observación i está fuera de la región del 95% de confianza del modelo cuando

$$T_i^2 > A (N^2 - 1) / (N(N - A)) F_{A, N-A}^{(0.05)}$$

¡Ojo si X son variables controladas o proceden de DOE!



Elipse T²-Hotelling (0.05)

$$\frac{t_a^2}{s_{t_a}^2} + \frac{t_b^2}{s_{t_b}^2} = \frac{2(N^2 - 1)}{N(N - 2)} F_{2, N-2}^{0.05}$$

Validación del modelo: Diagnóstico de observaciones

“Outliers” moderados – Obs. **ATÍPICAS**
(observaciones que no se ajustan al modelo PLS)

- Análisis de RESIDUOS E ó F (variabilidad no explicada por el modelo PLS)

$$\begin{array}{c} \begin{array}{|c|} \hline X \text{ ó } Y \\ \hline \end{array} \begin{array}{|c|} \hline K \text{ ó } M \\ \hline \end{array} - \begin{array}{|c|} \hline \hat{X} \text{ ó } \hat{Y} \\ \hline \end{array} \begin{array}{|c|} \hline K \text{ ó } M \\ \hline \end{array} = \begin{array}{|c|} \hline E \text{ ó } F \\ \hline \end{array} \begin{array}{|c|} \hline N \\ \hline \end{array} \begin{array}{|c|} \hline K \text{ ó } M \\ \hline \end{array} \begin{array}{|c|} \hline \text{Obs. } i \\ \hline \end{array} \end{array}$$



$$SCR_i = \sum_{k=1}^K e_{ik}^2 = \|e_i\|^2 \text{ ó } SCR_i = \sum_{m=1}^M f_{im}^2 = \|f_i\|^2$$

$$SCR = \sum_i (\sum_k e_{ik}^2) = \sum_i \sum_m f_{im}^2$$


- “Distancia” del individuo i al modelo en el **espacio X o Y** (distancia al hiperplano)

$$d_{i(X)} = \sqrt{\sum_k e_{ik}^2} = \sqrt{SCR_{X_i}} \text{ ó } d_{i(Y)} = \sqrt{\sum_m f_{im}^2} = \sqrt{SCR_{Y_i}}$$


Validación del modelo: Diagnóstico de observaciones



$$LCS(\alpha) = g \chi_h^2(\alpha)$$




Diferencias entre T_i^2 y SCR_i



- $Q_i = SCR_i$: bondad de ajuste del modelo a la observación i .
Distancia Euclídea de la observación i a su proyección en el (hiper)-plano formado por las nuevas A componentes del modelo $= \sqrt{SCR_i}$
- T_i^2 : suma de los cuadrados de los "scores" tipificados
Medida de la variación de cada muestra *dentro* del modelo
Distancia de Mahalanobis de la proyección a la media

Validación del modelo: Diagnóstico de variables



NOTA: Puede calcularse también el R^2 asociado a cada componente (no acumulado)

$R_k^2(\text{cum}) = \%$. Variabilidad de la variable k explicada por el modelo (A componentes)

$$R2VX(\text{cum}) \text{ ó } R2VY(\text{cum}) = \frac{SCE_k}{SCT_k} = 1 - \frac{SCR_k}{SCT_k}$$

$R_k^2 \text{adj}(\text{cum}) = \%$. Varianza de la variable k explicada por el modelo (A componentes)

$$R2VX\text{adj}(\text{cum}) \text{ ó } R2VY\text{adj}(\text{cum}) = 1 - \frac{SCR_k / \text{glr}}{SCT_k / \text{glr}}$$







$R^2(\text{cum}) = \%$. Variabilidad en X ó Y explicado por el modelo (A componentes)

$$R2X(\text{cum}) \text{ ó } R2Y(\text{cum}) = \frac{SCE}{SCT} = 1 - \frac{SCR}{SCT}$$

$R_k^2 \text{adj}(\text{cum}) = \%$. Varianza de X ó Y explicado por el modelo (A componentes)

$$R2X\text{adj}(\text{cum}) \text{ ó } R2Y\text{adj}(\text{cum}) = 1 - \frac{SCR / \text{glr}}{SCT / \text{glr}}$$

Diagnóstico de las variables: Bondad de ajuste (R^2)



¿Cuántas componentes PLS?: Validación Cruzada



- Eliminar un grupo de observaciones
- Ajustar el modelo con las observaciones restantes
- Predecir las primeras.

- PRESS (medida del error de predicción):

$$\text{Suma de cuadrados de los errores de predicción} = \sum_i \sum_m (y_{im} - \hat{y}_{im})^2$$

$\hat{y}_{im}$: Valor predicho para la observación i de la variable respuesta y_m con el modelo PLS ajustado sin dicha observación.

observac. i

X

Y

Fila eliminada

Q^2 (cum): Bondad de predicción:

Mide la potencia de predicción del modelo PLS con A componentes

$$Q^2(\text{cum}) = 1 - (\text{PRESS} / \text{SCT})$$


R^2 (cum) = Bondad de ajuste :

Evalúa el ajuste del modelo con A componentes a los datos

$$R^2(\text{cum}) = 1 - (\text{SCR} / \text{SCT})$$


$Q^2 > 0.5$ (Bueno); $Q^2 > 0.9$ (Excelente); $R^2 > Q^2$

Validación del modelo: Número de componentes



Aumentar innecesariamente el nº de componentes, provoca sobreajuste del modelo, lo que reduce su capacidad predictiva (Q^2 llega a disminuir)

Explotación del modelo PLS: Predicciones (1 componente)



Nota: el cálculo de los grados de libertad es objeto de debate científico en la actualidad


- Una nueva observación es considerada similar a la de las observaciones utilizadas para construir el modelo ("training set") si cae dentro de la región de tolerancia (cilíndrica en este caso por tratarse de una sola componente PLS) en el espacio X.
- Cuidado al realizar predicciones de observaciones que caen fuera de la región de tolerancia (gran imprecisión).
- La **varianza de la predicción** del valor medio de la respuesta y , dado un vector de observaciones x_0' , es:

$$V(\hat{y}_0) = \mathbf{t}_0' (\mathbf{T}'\mathbf{T})^{-1} \mathbf{t}_0 \sigma^2$$

- Un **intervalo de confianza** para m_y :

$$\hat{y}_0 \pm t_{\alpha/2}^{\text{glres}} \sqrt{V(\hat{y}_0)} \quad \hat{\sigma}^2 = \text{SCR}_y / (N - A - 1)$$

Explotación del modelo PLS: Predicciones (2 componentes)



- Proyectando las coordenadas de un nuevo individuo x_i sobre el plano de las dos primeras componentes en el espacio X, se obtienen sus scores t_{i1} y t_{i2} , de los que puede predecirse los scores u_{i1} y u_{i2} , a partir de los cuales, pueden predecirse los valores de las variables respuesta para dicho individuo, y_i .

Predicción vía PLS: Intervalos de confianza para la predicción media de una variable respuesta Y_M

Predicción del valor medio de $y_m / x_i \rightarrow \hat{y}_i$


1. Dado un nuevo vector de observaciones x_i' : $t_i' = x_i' W^*$
 $(1 \times A)$ $(1 \times K)$ $(K \times A)$

2. $\hat{y}_m = t_i' c_m$ (c_m : columna m-ésima de la matrix C')

$$\hat{Y}_m = T \times C_m \Rightarrow c_m = (T^T T)^{-1} T^T y_m; V(c_m) = (T^T T)^{-1} \sigma_f^2$$

$(N \times 1)$ $(N \times A)$ $(A \times 1)$

$$\text{Var}(\hat{y}_m) = t_i' V(c_m) t_i = t_i' (T^T T)^{-1} t_i \sigma_f^2$$



Intervalo de confianza al 95% para $E(y_m / x_i)$:

$$\hat{y}_m \pm t_{glr(0,05)} \sqrt{\text{var}(\hat{y}_m)}$$

Nota: Expresión aproximada, pues supone que T es matriz de regresores que no es función de Y , pero en PLS los scores T dependen de Y

Predicción vía PLS: Enfoque 1

Enfoque tradicional de regresión:

$$\begin{matrix} \boxed{\hat{Y}} & & \boxed{X} & & \boxed{\hat{B}} \\ N & & N & & K & & M \\ \hat{y}_i' & & x_i' & & \end{matrix}$$

• Expresión del modelo PLS en forma de regresión estándar:

$$\hat{Y} = X\hat{B} = TC^T \text{ pero } T = XW^*$$

$$\hat{Y} = XW(P^T W)^{-1} C^T$$

$$\hat{B}_{PLS} = W(P^T W)^{-1} C^T \quad \text{coeficientes escalados y centrados}$$

$$\hat{Y} = X\hat{B}_{PLS}$$

Predicción vía PLS: Enfoque 2

A partir de los pesos w :

1. Centrar y escalar los elementos x_i de $\mathbf{x}_i$ como en la matriz de datos original
2. Calcular: $\mathbf{t}_{i,a} = \mathbf{x}'_{i,a-1} \mathbf{w}_a / \mathbf{w}_a' \mathbf{w}_a$
3. Calcular el "residuo" $\mathbf{x}'_{i,a} = \mathbf{x}'_{i,a-1} - \mathbf{t}_{i,a} \mathbf{p}_a'$
4. Predecir y_i mediante: $\hat{y}_i = \bar{y} + \sum_{a=1}^A \mathbf{t}_{i,a} \mathbf{c}_a'$
5. Obtener el residuo de $\mathbf{x}_i$: $\mathbf{e}_i = \mathbf{x}_i - \mathbf{x}_{i,A}$
6. Obtener el vector de nuevos scores para el individuo i : $\mathbf{t}_{i,A}$ (con A componentes)
7. Diagnóstico de "outliers" (leverage, T^2 -Hotelling, SPE_{x_i} , DMODX_i ,...)

Nota: los scores $\mathbf{t}_a$ ($a=1, 2, \dots, A$) se calculan no a partir del vector de nuevas observaciones $\mathbf{x}'_i$, sino a partir del vector residual $\mathbf{x}'_{i,a-1}$ en cada iteración ($\mathbf{x}'_{i,0} = \mathbf{x}'_i$)

Predicción vía PLS: Enfoque 3

A partir de los pesos w^* :

- Expresión de $\mathbf{T}$ a partir de los datos originales $\mathbf{X}$:

$$\mathbf{t}_1 = \mathbf{X}_0 \mathbf{w}_1 \quad \mathbf{t}_2 = (\mathbf{X}_0 - \mathbf{t}_1 \mathbf{p}_1') \mathbf{w}_2 = \mathbf{X}_1 \mathbf{w}_2 \quad \mathbf{t}_3 = (\mathbf{X}_0 - \mathbf{t}_1 \mathbf{p}_1' - \mathbf{t}_2 \mathbf{p}_2') \mathbf{w}_3$$

- Se busca $\mathbf{T} = \mathbf{X} \mathbf{W}^* = \mathbf{X} \mathbf{W} \mathbf{M} \Rightarrow \mathbf{W}^* = \mathbf{W} \mathbf{M}$
- $\mathbf{T}^T \mathbf{T} = \mathbf{T}^T \mathbf{X} \mathbf{W} \mathbf{M} \Rightarrow \mathbf{M} = (\mathbf{T}^T \mathbf{X} \mathbf{W})^{-1} \mathbf{T}^T \mathbf{T}$
- Por otro lado: $\mathbf{X} = \mathbf{T} \mathbf{P}^T + \mathbf{E} \Rightarrow \mathbf{T}^T \mathbf{X} = \mathbf{T}^T \mathbf{T} \mathbf{P}^T + \mathbf{T}^T \mathbf{E} = \mathbf{T}^T \mathbf{T} \mathbf{P}^T$
- Equivalentemente: $\mathbf{W}^* = \mathbf{W} (\mathbf{P}^T \mathbf{W})^{-1} (\mathbf{T}^T \mathbf{T})^{-1} \mathbf{T}^T \mathbf{T} \Rightarrow \mathbf{W}^* = \mathbf{W} (\mathbf{P}^T \mathbf{W})^{-1}$
- Por tanto, $\mathbf{W}^* = \mathbf{W} \mathbf{M}$, donde $\mathbf{M} = (\mathbf{P}^T \mathbf{W})^{-1}$, de manera que $\mathbf{T} = \mathbf{X} \mathbf{W}^*$

$$\mathbf{t}'_i = \mathbf{x}'_i \mathbf{W}^*$$

$$\hat{y}_i = \mathbf{t}'_i \mathbf{C}'$$

$$\hat{\mathbf{x}}'_i = \mathbf{t}'_i \mathbf{P}'$$

$$\begin{matrix} \text{N} & & \text{A} & & \text{K} & & \text{A} \\ \boxed{\mathbf{T}} & = & \boxed{\mathbf{X}} & \boxed{\mathbf{W}^*} \\ \mathbf{t}'_i & & \mathbf{x}'_i & & \mathbf{w}^* \end{matrix}$$

$$\begin{matrix} & \text{M} & & \text{A} & & \text{M} \\ \text{N} & & \text{N} & & \text{K} & & \text{M} \\ \boxed{\hat{\mathbf{y}}_i} & = & \boxed{\mathbf{T}} & \boxed{\mathbf{C}'} \\ \mathbf{y}_i & & \mathbf{t}'_i & & \mathbf{c}' \end{matrix}$$

$$\begin{matrix} & \text{K} & & \text{A} & & \text{K} \\ \text{N} & & \text{N} & & \text{A} & & \text{K} \\ \boxed{\hat{\mathbf{X}}_i} & = & \boxed{\mathbf{T}} & \boxed{\mathbf{P}'} \\ \mathbf{x}'_i & & \mathbf{t}'_i & & \mathbf{p}' \end{matrix}$$

Predicción vía PLS

Ventajas de los enfoques 2 y 3 frente al enfoque 1:

- Manejan bien datos faltantes
- Predicen no sólo $\hat{y}_i$, sino también $\hat{x}_i \Rightarrow$ residuos
 - Diagnóstico de observaciones: detección de “outliers”
 - Leverages
 - T^2 -Hotelling
 - Posición t'_a en el plano
 - SPE ó DMOD en X e Y

Claves para la monitorización y diagnóstico de fallos

PLS: Resultados

Modelo de regresión (análogo a MLR): $y_m = Xb_m + f_m$

Coefficientes	b_{km}
Predicciones	$\hat{y}_m = x'_0 b_m$
Intervalos de confianza aproximados	IC (y_m / x'_0)
Residuos de y_m	f_{im}

Como PLS es un método de proyección:

Modelo de X	(ó Y)	t_{ia}	(u_{ia})
		p_{ak}, w_{ak}, w^*_{ak}	(c_{am})
Residuos X	(ó Y)	e_{ik}	(f_{im})

Validación del modelo (diagnóstico):

VIP _k	Importancia de la variable x_k (para explicar X e Y)
DmodX _i	Distancia obs. i al modelo (X)
DmodY	Distancia obs. i al modelo (Y)
Gráficos de “scores”	“clusters”, “outliers”, tendencias
Gráficos de pesos	Estructura correlación variables. Interpretación de las direcciones en los gráficos de “scores”

PLS: Cuestiones adicionales

- Relación con otros métodos predictivos multivariantes
- PLS no lineal
- PLS superficies de respuesta
- PLS-análisis discriminante
- PLS series temporales
- PLS y control estadístico de procesos multivariante (MSPC). Monitorización y diagnóstico de fallos en:
 - Procesos continuos y por lotes (“batch”)
- Inversión de modelos para optimización