

Deep Learning para el Diagnóstico de Cáncer de Mama: Clasificación con VGG16 y ResNet50, Fine-Tuning, Explicabilidad Grad-CAM y Segmentación U-Net sobre el Dataset BUSI

José Ramón Mena Pérez · Rafael Macián Castilla

Máster en Ingeniería de Análisis de Datos, Mejora de Procesos y Toma de Decisiones
Universitat Politècnica de València · Deep Learning en Python para el Modelado Predictivo

RESUMEN

Se propone un sistema de clasificación automática de ecografías de mama en tres clases (*benigno*, *maligno*, *normal*) mediante transferencia del conocimiento con VGG16 y ResNet50 preentrenadas en ImageNet. Se optimizan el *learning rate*, la tasa de Dropout y el grado de fine-tuning mediante validación cruzada estratificada ($k=4$) sobre una rejilla de 8 combinaciones, seleccionando para cada arquitectura la de mayor F1-macro medio. El modelo final se entrena con el número de épocas estimado por la propia validación cruzada y se evalúa una única vez sobre un conjunto de test independiente (20 %). Se implementa Grad-CAM para analizar la explicabilidad del clasificador y una U-Net para segmentación supervisada del tumor; los resultados evidencian que la explicabilidad de un clasificador, limitada por la baja resolución de su última capa convolucional, no equivale a una segmentación precisa a nivel de píxel.

1. INTRODUCCIÓN

El cáncer de mama es la neoplasia más frecuente en mujeres a nivel mundial, con más de 2,3 millones de nuevos casos en 2020 [1]. La ecografía es una técnica ampliamente utilizada por su bajo coste y ausencia de radiación ionizante; sin embargo, su interpretación introduce variabilidad interobservador.

Los sistemas CAD basados en CNN han demostrado resultados comparables a especialistas en imagen médica [2]. La transferencia del conocimiento permite adaptar modelos preentrenados en grandes colecciones como ImageNet a dominios con escasos datos. En este trabajo comparamos VGG16 [3] y ResNet50 [4] bajo fine-tuning controlado sobre BUSI [5], optimizamos hiperparámetros mediante validación cruzada, analizamos la explicabilidad con Grad-CAM [6] y entrenamos una U-Net [7] para segmentación supervisada del tumor. Los experimentos se realizaron en Google Colab [9] con GPU T4, y el desarrollo se apoyó en Claude Code [11].

2. MATERIALES Y MÉTODOS

2.1 Dataset BUSI

El dataset BUSI (*Breast Ultrasound Images*) [5, 8] contiene ecografías de mama etiquetadas en benigno, maligno y normal, con máscaras de segmentación del tumor. Tras la limpieza (eliminación de imágenes con anotaciones previas que podrían introducir sesgos en el modelo) se obtiene la distribución de la Fig. 1. El marcado desbalanceo (benigno $\gg$ maligno $>$ normal) justifica el F1-macro como métrica principal y el uso de *class_weight* en el entrenamiento.




Figura 1: Distribución de clases en el dataset BUSI limpio.




Figura 2: Ejemplos de imágenes del dataset BUSI (fila superior) y sus máscaras de segmentación superpuestas (fila inferior), una por clase.

La Fig. 3 muestra ejemplos representativos de las imágenes eliminadas: presentan carteles de orientación (*Right/Left*), marcas de la región tumoral o artefactos temporales que proporcionan pistas directas al modelo e

introducirían sesgo en el aprendizaje.




Figura 3: Ejemplos de imágenes eliminadas durante la limpieza (3 por clase). Las anotaciones previas visibles —carteles de orientación, zona del tumor señalada— constituyen un sesgo inaceptable para el modelo.

2.2 Preprocesado, Partición y Augmentation

Las imágenes se redimensionan a 224×224 px (RGB) y se normalizan con `imagenet_utils.preprocess_input`, la normalización estándar de ImageNet coherente con los pesos preentrenados de ambas arquitecturas. La partición estratificada (80 % entrenamiento / 20 % test) se fija con `SEED=42`. **No se reserva un conjunto de validación fijo:** los hiperparámetros se seleccionan mediante validación cruzada sobre el conjunto de entrenamiento. Los índices del split se reutilizan en la U-Net para garantizar un conjunto de test idéntico [10]. El *data augmentation* (rotaciones $\pm 15^\circ$, volteos horizontales, desplazamientos 10 %, zoom 10 %) se aplica únicamente en entrenamiento.

2.3 Arquitectura: Transferencia del Conocimiento

Se emplean VGG16 y ResNet50 preentrenadas en ImageNet sin clasificador (`include_top=False`). Sobre la base convolucional se añade un clasificador propio:

Flatten $\rightarrow$ Dense₂₅₆ $\rightarrow$ Dropout _{p} $\rightarrow$ Dense₁₂₈ $\rightarrow$ Dense₃^{softmax}

El Dropout se aplica **únicamente** entre las capas *Dense* del clasificador propio, nunca en la base convolucional preentrenada; esto preserva las representaciones aprendidas en ImageNet mientras regulariza solo las capas nuevas. Su tasa p no se fija a priori: es uno de los hiperparámetros optimizados por la validación cruzada ($p \in \{0, 0.5\}$). El parámetro n_{bloques} controla el fine-tuning: con $n_{\text{bloques}}=0$ la base permanece completamente congelada; con $n_{\text{bloques}}=1$ se descongela el último bloque convolucional (`block5` en VGG16, `conv5` en ResNet50). Las capas `BatchNormalization` se mantienen *siempre* congeladas —incluso al descongelar bloques convolucionales— para preservar el *running mean* y *running variance* estimados durante el preentrenamiento en ImageNet; actualizarlos con un dataset pequeño degradaría la normalización interna y desestabilizaría el entrenamiento.

2.4 Validación Cruzada y Estrategia de Entrenamiento

Se optimizan tres hiperparámetros mediante `StratifiedKfold` ($k=4$) sobre el conjunto de entrenamiento: el learning rate ($\text{lr} \in \{10^{-4}, 10^{-5}\}$), la tasa de Dropout ($p \in \{0, 0.5\}$) y el grado de fine-tuning ($n_{\text{bloques}} \in \{0, 1\}$), lo que define una rejilla de **8 combinaciones**. Cada combinación se entrena en los 4 folds con augmentation, *class_weight* y `EarlyStopping` (`val_loss`, paciencia = 5, máximo 30 épocas). Para cada fold se registran el F1-macro sobre el fold de validación y las *épocas útiles* (épocas entrenadas —paciencia, correspondientes a la mejor `val_loss`); se reportan la media y la desviación típica de ambas magnitudes sobre los 4 folds.

La combinación ganadora de cada arquitectura es la de mayor F1-macro medio. El **modelo final** se entrena sobre el 80 % completo de entrenamiento durante un número de épocas igual a la media de las épocas útiles de los 4 folds de esa combinación —sin conjunto de validación ni `EarlyStopping`— y se evalúa una única vez sobre el 20 % de test.

3. RESULTADOS

3.1 Validación Cruzada

La Tabla 1 recoge, para las 8 combinaciones de cada arquitectura, el F1-macro y las épocas útiles promediados sobre los 4 folds, con su desviación típica; la Fig. 4 compara visualmente el F1-macro. La combinación ganadora de cada modelo —la de mayor F1-macro medio— fija los hiperparámetros y la duración del entrenamiento final.

Cuadro 1: Validación cruzada 4-fold: F1-macro y épocas útiles (media $\pm$ desv. típica) de las 8 combinaciones, ordenadas por F1-macro. Fila en **negrita** = combinación ganadora.

Modelo	lr	p	n_b	F1-macro	épocas
VGG16	10^{-4}	0.0	0	0.000$\pm$0.000	0.0$\pm$0.0
	10^{-4}	0.0	0	0.000$\pm$0.000	0.0$\pm$0.0
	10^{-4}	0.0	0	0.000$\pm$0.000	0.0$\pm$0.0
	10^{-4}	0.0	0	0.000$\pm$0.000	0.0$\pm$0.0
	10^{-4}	0.0	0	0.000$\pm$0.000	0.0$\pm$0.0
	10^{-4}	0.0	0	0.000$\pm$0.000	0.0$\pm$0.0
	10^{-4}	0.0	0	0.000$\pm$0.000	0.0$\pm$0.0
	10^{-4}	0.0	0	0.000$\pm$0.000	0.0$\pm$0.0
ResNet50	10^{-4}	0.0	0	0.000$\pm$0.000	0.0$\pm$0.0
	10^{-4}	0.0	0	0.000$\pm$0.000	0.0$\pm$0.0
	10^{-4}	0.0	0	0.000$\pm$0.000	0.0$\pm$0.0
	10^{-4}	0.0	0	0.000$\pm$0.000	0.0$\pm$0.0
	10^{-4}	0.0	0	0.000$\pm$0.000	0.0$\pm$0.0
	10^{-4}	0.0	0	0.000$\pm$0.000	0.0$\pm$0.0
	10^{-4}	0.0	0	0.000$\pm$0.000	0.0$\pm$0.0
	10^{-4}	0.0	0	0.000$\pm$0.000	0.0$\pm$0.0

La combinación ganadora de cada arquitectura aparece en la primera fila de su bloque en la Tabla 1. La desviación típica sobre los 4 folds cuantifica la estabilidad de cada configuración: una desviación baja indica que el rendimiento apenas depende del fold concreto, mientras que una desviación alta señala sensibilidad a la partición de los datos. La inclusión del Dropout en la rejilla permite

comprobar empíricamente si la regularización mejora la generalización: basta comparar, a igualdad de lr y n_b , las combinaciones $p=0$ y $p=0,5$.




Figura 4: F1-macro por combinación en validación cruzada 4-fold (media y desviación típica). Barra verde = combinación ganadora.

3.2 Evaluación en Test

La Tabla 2 recoge las métricas sobre el conjunto de test (20 %), separado desde el inicio y no utilizado en ninguna fase de entrenamiento ni selección de hiperparámetros.

Cuadro 2: Métricas del modelo definitivo sobre el conjunto de test (20 %).

Modelo	Accuracy	F1-macro	AUC
VGG16	0.XXX	0.XXX	0.XXX
ResNet50	0.XXX	0.XXX	0.XXX

La Tabla 2 compara ambas arquitecturas en accuracy, F1-macro y AUC; el F1-macro es la métrica de referencia por el desbalanceo de clases. Las matrices de confusión (Fig. 5) detallan los aciertos y errores por clase. El caso clínicamente más grave es el falso negativo en la clase *maligno*, ya que implica no detectar un tumor maligno. [Comentar, a partir de las matrices y la tabla obtenidas, qué modelo ofrece mejores métricas globales y cómo se comporta cada uno en la clase maligno y en la clase benigno.]




Figura 5: Matrices de confusión sobre el conjunto de test para VGG16 y ResNet50.

3.3 Explicabilidad con Grad-CAM

Grad-CAM [6] genera mapas de calor a partir de los gradientes de la última capa convolucional (`block5_conv3` para VGG16, `conv5_block3_out` para ResNet50), sin necesidad de máscaras de entrenamiento: surge directamente como subproducto del clasificador. La resolución nativa del mapa es 7×7 (factor de submuestreo de 32 respecto a 224×224), lo que limita intrínsecamente la

precisión de localización. La Fig. 6 muestra ejemplos sobre imágenes de test.




Figura 6: Grad-CAM sobre imágenes de test (una por clase). Izq: imagen original. Centro: VGG16. Dcha: ResNet50.

La Tabla 3 cuantifica la calidad de localización comparando el mapa de calor con la máscara real del tumor mediante cuatro métricas: IoU y DICE miden el solapamiento global; *inside_frac* indica la fracción de activación que cae dentro de la máscara; *acierto_pico* comprueba si el píxel de máxima activación pertenece a la región tumoral.

Cuadro 3: Métricas de localización Grad-CAM vs máscara real (test).

	IoU	DICE	ins._frac	pico
VGG16	0.XXX	0.XXX	0.XXX	XX %
ResNet50	0.XXX	0.XXX	0.XXX	XX %

Las cuatro métricas se calculan únicamente sobre las imágenes con tumor (benigno y maligno) del test, ya que las imágenes normales no disponen de máscara de referencia; cada valor es la media sobre dichas imágenes. Los valores de IoU y DICE son reducidos en ambos modelos: el Grad-CAM señala una región aproximada y no un contorno preciso del tumor, consecuencia directa de la resolución 7×7 de la última capa convolucional. [Indicar, a partir de la Tabla 3, qué modelo localiza mejor el tumor y, por tanto, qué arquitectura se prefiere para el análisis Grad-CAM.]

3.4 Segmentación U-Net y Comparativa

Para ampliar el análisis de localización con una técnica de segmentación supervisada a nivel de píxel, entrenamos una U-Net [7]. Reutilizamos exactamente el mismo conjunto de test (20 %) que en la clasificación, garantizando que la comparación sea justa; la U-Net extrae además una validación interna del conjunto de entrenamiento para su EarlyStopping. A diferencia del Grad-CAM, la U-Net recibe las máscaras de segmentación como supervisión directa y aprende a predecir la localización del tumor de forma explícita.

La Tabla 4 compara IoU y DICE entre U-Net y Grad-CAM. La Fig. 7 muestra ejemplos visuales de las predic-

ciones.

Cuadro 4: Comparativa de localización: Grad-CAM vs U-Net (test).

	IoU	DICE
VGG16 (Grad-CAM)	0.XXX	0.XXX
ResNet50 (Grad-CAM)	0.XXX	0.XXX
U-Net	0.XXX	0.XXX




Figura 7: Comparativa de localización: Grad-CAM vs U-Net sobre imágenes de test.

Como era de esperar, la U-Net obtiene un IoU y un DICE muy superiores a los del Grad-CAM. Sin embargo, esta comparación no es completamente equivalente: la U-Net utiliza las máscaras de segmentación como etiquetas de entrenamiento, mientras que el Grad-CAM emerge sin ninguna anotación de localización. El Grad-CAM es, por tanto, especialmente valioso cuando no se dispone de anotaciones de píxel, siendo una herramienta de explicabilidad complementaria, no sustituta, de la segmentación supervisada.

4. CONCLUSIONES

Se han comparado VGG16 y ResNet50 para la clasificación de ecografías de mama mediante transferencia del conocimiento. Los hiperparámetros —learning rate, tasa de Dropout y grado de fine-tuning— se han optimizado con una validación cruzada estratificada de 4 folds sobre 8 combinaciones, y el modelo final se ha entrenado con el número de épocas estimado por la propia validación cruzada, evaluándose una única vez sobre un conjunto de test independiente. El análisis Grad-CAM muestra que los modelos activan regiones próximas al tumor, pero con localización gruesa debida a la baja resolución de la última capa convolucional (7×7). La U-Net, al ser un modelo supervisado con anotaciones de píxel, proporciona segmentaciones notablemente más precisas en IoU y DICE: la explicabilidad de un clasificador no sustituye a una segmentación entrenada. Como limitación principal, el dataset es pequeño y desbalanceado; ampliar con datos externos y técnicas de aumento mejoraría la generalización. El código y modelos están disponibles en GitHub [12].

REFERENCIAS

- [1] H. Sung *et al.*, “Global Cancer Statistics 2020,” *CA: A Cancer Journal for Clinicians*, vol. 71, no. 3, pp. 209–249, 2021.
- [2] G. Litjens *et al.*, “A survey on deep learning in medical image analysis,” *Medical Image Analysis*, vol. 42, pp. 60–88, 2017.
- [3] K. Simonyan and A. Zisserman, “Very Deep Convolutional Networks for Large-Scale Image Recognition,” in *Proc. ICLR*, 2015.
- [4] K. He, X. Zhang, S. Ren, and J. Sun, “Deep Residual Learning for Image Recognition,” in *Proc. CVPR*, pp. 770–778, 2016.
- [5] W. Al-Dhabyani, M. Gomaa, H. Khaled, and A. Fahmy, “Dataset of breast ultrasound images,” *Data in Brief*, vol. 28, p. 104863, 2020.
- [6] R. R. Selvaraju *et al.*, “Grad-CAM: Visual Explanations from Deep Networks via Gradient-based Localization,” in *Proc. ICCV*, pp. 618–626, 2017.
- [7] O. Ronneberger, P. Fischer, and T. Brox, “U-Net: Convolutional Networks for Biomedical Image Segmentation,” in *Proc. MICCAI*, pp. 234–241, 2015.
- [8] Kaggle, *Breast Ultrasound Images Dataset*, 2020.
- [9] Google, *Google Colaboratory*, 2017.
- [10] Material docente, *Deep Learning en Python para el Modelado Predictivo*, Máster IAMDPTD, Universitat Politècnica de València, curso 2025–2026.
- [11] Anthropic, *Claude Code: AI-Assisted Software Development*, 2024.
- [12] J. R. Mena Pérez and R. Macián Castilla, *Repositorio BUSI Deep Learning*, GitHub, 2026.