

Diseño, desarrollo y validación de un framework de detección y clasificación de figuras mitóticas en histopatología de cáncer de mama:

de los modelos convolucionales a los modelos fundacionales

Autor **José Ramón Mena Pérez**

Tutor **Adrián Colomer Granero**

Cotutor **Alejandro Golfe San Martín**

Máster U. en Ingeniería de Análisis de Datos, Mejora de Procesos y Toma de Decisiones

Universitat Politècnica de València · Curso 2025 / 2026

Índice

1 Contexto clínico y motivación

2 Inteligencia artificial

3 Objetivos

4 Materiales

5 Metodología

6 Resultados

7 Conclusiones y trabajo futuro

01


Contexto clínico y motivación

Un problema que crece, cómo se ha medido siempre y qué cambia con la patología digital

El cáncer de mama: un problema que crece


El tumor más frecuente en mujeres y, en conjunto, el segundo más diagnosticado en España

En el mundo · 2024 *(estimaciones)*



11,8 % de todos los cánceres · el más frecuente en mujeres, en casos y en muertes

Proyección para 2050 *(variación respecto a 2022)*




El pronóstico depende en gran medida del estadio al diagnóstico y de la **caracterización histopatológica del tumor.**

Antes de la digitalización: el recuento de MITOSIS al microscopio

Durante décadas, contar mitosis fue mirar por el ocular y contarlas a mano

- El patólogo recorre la preparación al microscopio, busca las zonas de **mayor actividad** y cuenta las mitosis una a una.
- Es un recuento **manual, lento y subjetivo**: dos observadores pueden obtener recuentos distintos sobre el mismo tumor.



Consecuencia: un recuento lento y con mucha variabilidad entre observadores.

Patología digital: del tumor al píxel

La digitalización de la preparación es lo que permite analizar el tejido con un ordenador



1 · Pieza tumoral

se extirpa el tumor de mama




2 · Tinción H&E

cortes de 5 μ m, teñidos



3 · Portaobjetos


la preparación de vidrio



4 · Imagen digital

la WSI, ya en píxeles


Una WSI: el portaobjetos entero, en gigapíxeles



Escala gigapíxel (del orden de 100.000×100.000 px): se navega como un mapa y no cabe entera en una red → hay que trocearla en parches.

De la WSI a la región donde se cuenta


- La lógica del recuento **no cambia**: se delimita una región de interés (ROI) en la zona de mayor actividad.
- La ROI son **2 mm² ≈ 10 HPF**, igual que al microscopio.
- Las imágenes con las que se trabaja son **frames**: un frame puede abarcar uno o varios HPF.
- Un HPF es un **área**, no una imagen: la densidad se expresa por 2 mm².



Relación entre frame, HPF y ROI.

¿Y por qué contar mitosis?

- El **grado de Nottingham** suma tres componentes: formación de túbulos, pleomorfismo nuclear y recuento de mitosis.
- Las mitosis son el componente que mide la **velocidad de proliferación** del tumor.
- **Son escasas**: en esta ROI hay 12 mitosis frente a 121 imitaciones.
- Se anotan por **consenso de varios patólogos**: MITOS-ATYPIA-14, tres expertos; TUPAC16, dos.



ROI real anotada: 12 mitosis (verde) frente a 121 imitaciones (naranja).

Puntuación mitótica (por 2 mm²)


< 10 → 1 punto · 10-20 → 2 · > 20 → 3

Grado final (suma de los tres componentes)

I: 3-5 · II: 6-7 · III: 8-9 → peor pronóstico


¿Qué es una mitosis? Sus cuatro fases

Una célula sorprendida en división, repartiendo sus cromosomas en dos células hijas idénticas




Profase

la cromatina se condensa en cromosomas



Metafase

se alinean en la placa ecuatorial



Anafase

las cromátidas migran a los polos



Telofase


dos núcleos hijos ya separados

La forma cambia mucho de una fase a otra — **y esa variabilidad dificulta reconocerlas, tanto al patólogo como a un sistema automático.**

El reto: a simple vista, la mitosis engaña

Las mitosis son escasas y, además, hay muchas estructuras que se les parecen

- **Escasez.** Unas pocas mitosis entre miles de células: hay que revisar muchísimo tejido.
- **Células apoptóticas.** Mueren de forma programada y su cromatina condensada imita una mitosis: son el falso positivo más frecuente.
- **Otros imitadores.** Núcleos hipercromáticos, picnóticos o cariorréticos, linfocitos y artefactos de corte o tinción.
- **Escala gigapíxel.** Hay que trocear en parches y recomponer después.




Una mitosis real (verde) frente a tres imitaciones (naranja).

La consecuencia: distinguir una mitosis de una imitación es la principal fuente de error de la tarea.


Y además, cada escáner ve distinto

El mismo tipo de tejido, con la misma tinción, digitalizado por dos equipos diferentes



Aperio

MITOS-ATYPIA-14



Leica

TUPAC16


02

Inteligencia artificial

Redes convolucionales, transformers, modelos fundacionales y su adaptación eficiente

Redes neuronales convolucionales (CNN)


La familia que ha dominado durante años la visión por computador y la detección de mitosis



- Mira la imagen **por trozos pequeños**, con filtros que se deslizan buscando patrones: primero bordes y texturas, después formas completas.
- Con esos patrones decide **qué hay y dónde está**, dibujando una caja alrededor de cada objeto.
- Es la familia clásica de la visión por computador y encaja muy bien con la textura del tejido.

Transformers: la atención llega a la imagen

En lugar de mirar vecindarios locales, cada parte de la imagen se relaciona con todas las demás




- Trocea la imagen en parches y los trata **como si fueran palabras** de una frase.
- Cada parche **se compara con todos los demás** y se queda con lo que le resulta relevante: es la atención.
- Así ve la imagen entera desde el principio: aporta **contexto**, no solo el vecindario de cada zona.

La diferencia clave: la CNN mira de cerca y va ampliando; el transformer ve la imagen entera desde el principio.

Modelos fundacionales

Redes de gran tamaño preentrenadas sin etiquetas y reutilizables en multitud de tareas



volúmenes masivos de imágenes sin etiquetar

**preentrenamiento
auto-supervisado**



**Modelo
fundacional**
representaciones generales

Clasificación de subtipos tumorales

Predicción de biomarcadores

Pronóstico de supervivencia


Detección y recuento de estructuras

- Es una red enorme entrenada con **millones de imágenes sin etiquetar**: nadie tuvo que decirle qué había en cada una.
- No resuelve una tarea concreta: aprende a **describir el tejido**, a resumir cada imagen en una lista de números.
- Sobre esa descripción se pueden realizar otro tipo de tareas secundarias.

Adaptación eficiente: LoRA

Especializar el modelo fundacional a una tarea concreta sin reentrenarlo entero

- Si la tarea es muy fina, la descripción general **se queda corta**: conviene especializar el propio modelo.
- Pero reentrenarlo entero es **caro** y, con pocos datos, puede hacer que **olvide lo que sabía**.
- **LoRA** congela los pesos originales y entrena solo una corrección pequeña al lado: una fracción mínima del modelo.



$$\mathbf{h} = \mathbf{W} \mathbf{x} + (\alpha / r) \cdot \mathbf{B} \mathbf{A} \mathbf{x}$$

α / r regula cuánto pesa la corrección frente al modelo original

La idea: especializar el modelo sin tocar lo que ya sabe, añadiendo al lado una corrección pequeña y entrenable.

03

Objetivos

Qué persigue este trabajo

Objetivos del trabajo

1

Diseñar

un sistema de dos fases: detector como generador de candidatos + modelo fundacional como clasificador de refinamiento.

2

Evaluar

el efecto de adaptar el modelo fundacional con LoRA frente a usarlo sin adaptar.

3

Validar

la reproducibilidad de los hallazgos en dos conjuntos públicos e independientes.


04

Materiales

Los dos conjuntos públicos de cáncer de mama empleados

MITOS-ATYPIA-14 · ICPR 2014


- **16 pacientes**, cada uno digitalizado por **dos escáneres** (Aperio y Hamamatsu) sobre el mismo tejido.
- **952 / 957 mitosis** y unas 3.900 imitaciones por escáner, anotadas por consenso de tres patólogos.
- **1.696 frames por escáner** a 40× (0,2455 y 0,2274 $\mu\text{m}/\text{px}$).



El mismo tejido, dos escáneres.

TUPAC16

- **73 casos** de carcinoma de mama invasivo, a 0,25 $\mu\text{m}/\text{px}$.
- Dos escáneres (Aperio y Leica) y dos formatos: **multi-frame y single-frame**.
- **1.898 mitosis y 5.340 imitaciones**, anotadas por consenso de dos patólogos.
- Un segundo dominio independiente para **replicar el estudio**.



Formatos multi-frame y single-frame.

05

Metodología

Arquitecturas empleadas, protocolo, construcción de parches, evaluación y segunda fase

Las arquitecturas empleadas

Dos detectores de familias distintas, comparados bajo el mismo protocolo, y un modelo fundacional como segunda fase

Detector · transformer

RF-DETR

- Familia DETR (Roboflow), para tiempo real.
- Predicción de conjuntos: sin anclas y sin NMS.
- Backbone DINOv2 preentrenado; se reentrena entero.
- Versión Small: ~31,8 M de parámetros.

Resultados competitivos en MIDOG 2025 (F1 0,789).

Detector · convolucional

YOLO26

- You Only Look Once: una sola pasada sobre la imagen.
- Conservador: dispara menos y acierta más.
- Pesos preentrenados; se reentrena entero.
- Versión Small: ~10 M de parámetros.

La familia de referencia en detección desde 2016.

Modelo fundacional


Virchow

- Vision Transformer de 632 M, preentrenado sin etiquetas.
- Uno de los primeros fundacionales de patología.
- Trabaja a nivel de parche: encaja con clasificar candidatos.
- Demasiado grande para reentrenarlo: se adapta con LoRA.

Es la segunda fase del sistema.

Entrenamiento: los dos detectores se ajustan por completo; el fundacional, de 632 M de parámetros, se adapta con LoRA.

El sistema propuesto: dos fases



Fase 1: el detector echa la red ancha (alta sensibilidad). **Fase 2:** el fundacional filtra los falsos positivos.

El punto de partida: los splits del estado del arte

El protocolo de partición se toma de la literatura, con ligeras modificaciones, para que los resultados sean comparables

- Para estos conjuntos existen **muchas particiones distintas**: se adoptan las ya empleadas en el estado del arte, con ligeras modificaciones.
- MITOS-ATYPIA-14: **validación cruzada dejando un paciente fuera** (leave-one-out, 10 folds), con el paciente A04 fijo como test.
- TUPAC16: **partición única por paciente (53 / 10 / 10)**, con los dos escáneres representados en validación y test.
- Cada paciente entra con sus dos escáneres juntos: **sin fugas entre particiones**.


Motivo: comparabilidad directa con la literatura. La aportación de este trabajo es lo que se monta encima: detectores modernos y una segunda fase con un modelo fundacional.

Los parches para validar y para evaluar

Dos formas de recortar el tejido, según lo que se quiera medir

Validación


Coverage



- Un parche por grupo de anotaciones.
- Cada mitosis aparece una sola vez: la métrica no se infla con duplicados.

Test


Sliding window



- Rejilla que recorre el frame entero, con solapamiento.
- Las detecciones repetidas en los solapes se fusionan en una.

Oversampling: una misma mitosis, muchos recortes

Así se compensa que las mitosis sean escasísimas frente al resto del tejido




Cada recuadro es un recorte distinto sobre la misma mitosis.

- La mitosis, marcada en el centro, se replica en varias versiones: **5 ángulos × 3 reflexiones**.
- Cada recuadro es un **recorte nuevo sobre el tejido original**, con el centro desplazado al azar.
- Por eso la mitosis **no queda siempre centrada**: el modelo la ve en distintas posiciones y con distinto contexto.
- Y al recortar del tejido real, **no hay bordes rellenos** ni esquinas vacías.

El objetivo: equilibrar las clases en entrenamiento sin inventar tejido que no existe.

Fase 2: clasificación de candidatos

Cada candidato del detector pasa por Virchow y un clasificador decide si es una mitosis real



06

Resultados

El sistema de dos fases en MITOS-ATYPIA-14 y TUPAC16

Detección en validación · MITOS-ATYPIA-14

Media ± desviación típica entre folds en MITOS-ATYPIA-14 · modelo único en TUPAC16

	Confianza 0,3			Confianza 0,5		
Modelo	P	R	F ₁	P	R	F ₁
RF-DETR · ovs	0,498 ± 0,20	0,735 ± 0,19	0,562 ± 0,17	0,638 ± 0,21	0,584 ± 0,20	0,572 ± 0,18
RF-DETR · sin ovs	0,540 ± 0,22	0,542 ± 0,21	0,516 ± 0,19	0,646 ± 0,29	0,351 ± 0,18	0,430 ± 0,19
YOLO26 · ovs	0,670 ± 0,21	0,644 ± 0,21	0,605 ± 0,16	0,731 ± 0,18	0,501 ± 0,23	0,534 ± 0,16
YOLO26 · sin ovs	0,692 ± 0,18	0,431 ± 0,20	0,485 ± 0,15	0,792 ± 0,18	0,255 ± 0,17	0,343 ± 0,15

MITOS-ATYPIA-14, detección en VALIDACIÓN (parches coverage, distancia). Media ± std de los 10 folds.

Detección en test · MITOS-ATYPIA-14

Media ± desviación típica entre folds en MITOS-ATYPIA-14 · modelo único en TUPAC16

	Confianza 0,3			Confianza 0,5		
Modelo	P	R	F ₁	P	R	F ₁
RF-DETR · ovs	0,471 ± 0,03	0,908 ± 0,01	0,620 ± 0,03	0,685 ± 0,02	0,786 ± 0,02	0,732 ± 0,01
RF-DETR · sin ovs	0,586 ± 0,02	0,808 ± 0,03	0,679 ± 0,02	0,762 ± 0,06	0,623 ± 0,04	0,682 ± 0,01
YOLO26 · ovs	0,693 ± 0,04	0,759 ± 0,05	0,722 ± 0,02	0,778 ± 0,03	0,593 ± 0,08	0,668 ± 0,04
YOLO26 · sin ovs	0,775 ± 0,03	0,576 ± 0,11	0,652 ± 0,07	0,838 ± 0,03	0,348 ± 0,13	0,474 ± 0,15

MITOS-ATYPIA-14, detección en TEST (ventana deslizante, distancia). Media ± std de los 10 folds.

Segunda fase en MITOS-ATYPIA-14

Media ± desviación típica entre folds en MITOS-ATYPIA-14 · modelo único en TUPAC16

Sistema (confianza det. 0,3)	P	R	F ₁
Detector solo	0,470 ± 0,03	0,909 ± 0,01	0,619 ± 0,03
+ Virchow frozen (τ = 0,30)	0,734 ± 0,02	0,619 ± 0,01	0,671 ± 0,01
+ Virchow LoRA (τ = 0,20)	0,752 ± 0,01	0,835 ± 0,01	0,791 ± 0,003

MITOS-ATYPIA-14, sistema de dos fases en TEST (distancia). Umbrales del clasificador fijados en validación (frozen τ = 0,30; LoRA τ = 0,20). Media ± std de 10 folds en F₁.

Detección en validación · TUPAC16

Media ± desviación típica entre folds en MITOS-ATYPIA-14 · modelo único en TUPAC16

	Confianza 0,3			Confianza 0,5		
Modelo	P	R	F ₁	P	R	F ₁
RF-DETR · ovs	0,634	0,823	0,716	0,756	0,705	0,730
RF-DETR · sin ovs	0,588	0,742	0,656	0,762	0,615	0,681
YOLO26 · ovs	0,729	0,768	0,748	0,839	0,652	0,734
YOLO26 · sin ovs	0,763	0,678	0,718	0,852	0,586	0,695

TUPAC16, detección en VALIDACIÓN (parches coverage, distancia). Modelo único.

Detección en test · TUPAC16

Media ± desviación típica entre folds en MITOS-ATYPIA-14 · modelo único en TUPAC16

	Confianza 0,3			Confianza 0,5		
Modelo	P	R	F ₁	P	R	F ₁
RF-DETR · ovs	0,405	0,939	0,566	0,597	0,845	0,700
RF-DETR · sin ovs	0,409	0,866	0,556	0,638	0,720	0,677
YOLO26 · ovs	0,612	0,895	0,727	0,715	0,811	0,760
YOLO26 · sin ovs	0,667	0,838	0,743	0,747	0,779	0,762

TUPAC16, detección en TEST (ventana deslizante, distancia). Modelo único.

Segunda fase en TUPAC16

Media ± desviación típica entre folds en MITOS-ATYPIA-14 · modelo único en TUPAC16

Sistema (confianza det. 0,3)	P	R	F ₁
Detector solo	0,405	0,939	0,566
+ Virchow frozen ($\tau = 0,25$)	0,632	0,759	0,689
+ Virchow LoRA ($\tau = 0,85$)	0,786	0,736	0,760

TUPAC16, sistema de dos fases en TEST (distancia). Umbrales del clasificador fijados en validación (frozen $\tau = 0,25$; LoRA $\tau = 0,85$). Modelo único.

Filtrado de falsos positivos por la segunda fase

Media ± desviación típica entre folds en MITOS-ATYPIA-14 · modelo único en TUPAC16

Conjunto	Clasificador	FP_empty	FP_hard	Mitosis perd.
MITOS-ATYPIA-14	Virchow frozen	390/480 (81%)	41/69 (58%)	154/482 (32%)
	Virchow LoRA	376/480 (78%)	27/69 (38%)	39/482 (8%)
TUPAC16	Virchow frozen	290/375 (77%)	121/230 (53%)	79/412 (19%)
	Virchow LoRA	346/375 (92%)	171/230 (74%)	89/412 (22%)

Falsos positivos eliminados por el clasificador (conf. detector 0,3; distancia; umbral fijo de validación): fondo (FP_empty) frente a imitaciones (FP_hard), y mitosis reales perdidas.
Formato: eliminados/total (%). En MITOS-ATYPIA-14 los recuentos son aproximados (media de los 10 folds); TUPAC = modelo único.

07

Conclusiones y trabajo futuro

Principales aportaciones y líneas abiertas

Conclusiones

1

RF-DETR como generador de candidatos

El detector transformer alcanza el mayor recall y es el mejor generador de candidatos; el convolucional es más preciso, pero se deja mitosis por el camino.

2

El fundacional adaptado como 2.^a fase

Virchow adaptado con LoRA filtra los falsos positivos casi sin perder mitosis y supera con claridad al modelo congelado.

3

Un framework que funciona en ambos conjuntos

El sistema de dos fases rinde bien en MITOS-ATYPIA-14 y en TUPAC16, con escáneres y protocolos distintos: F_1 de 0,619 a 0,791 y de 0,566 a 0,760.

Líneas futuras

Lo que este trabajo deja abierto, agrupado en tres frentes

Modelo fundacional


- Probar otros modelos fundacionales de patología.
- Explorar distintas adaptaciones y rangos de LoRA.

Detectores

- Relacionar la confianza del detector con el grado de confianza que el patólogo asigna a cada mitosis.

Datos y validación

- Explorar otros datasets



Agradecimientos

Al tutor, Adrián Colomer, al cotutor, Alejandro Golfe, y al grupo CVBLab (HUMAN-tech, UPV),
por su guía y por el marco de investigación de este trabajo (proyecto FOMENT).

A la familia y a los compañeros, por el apoyo durante el máster.

¡Gracias por su atención!

¿Preguntas?

